

Interpretowalność klasyfikatora gatunku na muzyce symbolicznej

Członkowie zespołu:

- Karol Łukasik
- Grzegorz Aronowski
- Adam Czupryński

1. Cel projektu

Projekt polega na wytrenowaniu klasyfikatora gatunku na wybranych datasetach MIDI i zastosowaniu metod concept-based interpretability do analizy, które cechy model uznaje za charakterystyczne dla każdego gatunku.

2. Hipotezy badawcze

Przed przystąpieniem do fazy eksperymentalnej, sformułowano następujące hipotezy badawcze dotyczące zachowania trenowanego klasyfikatora:

Hipoteza 1: Model głęboki wyuczony na muzyce symbolicznej oprze swoje decyzje klasyfikacyjne na cechach zbieżnych z teorią muzyki, co zostanie potwierdzone wysokim, dodatnim wynikiem TCAV Score dla intuicyjnych par (np. ilość nut basowych a muzyka elektroniczna).

Hipoteza 2: Koncept dominacji basu będzie statystycznie istotnym i silnie pozytywnym czynnikiem decyzyjnym dla gatunków takich jak Rap oraz Electronic, odróżniając je od gatunków opartych na wyższych częstotliwościach (np. Folk, Vocal).

Hipoteza 3: Płytsza architektura ResNet18 osiągnie wyższą skuteczność klasyfikacyjną i lepsze właściwości generalizacyjne na zbiorze testowym w porównaniu do głębszego modelu ResNet34. Głębsza sieć o większej pojemności (ResNet34) będzie wykazywać silniejszą tendencję do przeuczenia (*overfitting*).

Hipoteza 4: Występowanie dysonansowego interwału trytonu będzie rozpoznawane przez klasyfikator jako silny, pozytywny sygnał dla gatunków o złożonej strukturze harmoniczej (np. Jazz), podczas gdy dla utworów o charakterze stricte konsonansowym (np. New Age, Pop_Rock) koncept ten okaże się statystycznie nieistotny lub negatywny.

3. Zdefiniowane koncepty muzyczne

Na potrzeby eksperymentu zaimplementowano zautomatyzowane algorytmy ekstrakcji następujących konceptów bezpośrednio z przetworzonej bazy danych (wybrano po 100 utworów o najwyższym natężeniu danej cechy):

- Four-on-the-floor (Stopa 4/4): Regularne, miarowe uderzenia bębna basowego (stopy) na każdą ćwierćnutę w takcie. Jest to fundament muzyki tanecznej, elektronicznej (EDM) oraz disco. Algorytm analizuje wyłącznie kanał perkusyjny macierzy MIDI (ścieżka drums), skupiając się na nutach o wartościach 35 oraz 36. Zlicza stosunek uderzeń, które idealnie "trafiają w punkt" (z niewielką tolerancją błędów), do wszystkich poprawnych uderzeń w utworze. Do konceptu trafia elita 100 utworów o najwyższym wskaźniku.
- High Polyphony (Wysoka polifonia): Równoczesne brzmienie powyżej 12 nut,
- Perfect Fifth: Występowanie interwału kwinty czystej. Koncept mierzony jako względna częstość występowania interwału kwinty czystej (7 półtonów) w sekwencjach MIDI. Wskaźnik ten ma służyć odróżnieniu muzyki opartej na harmonii (gdzie wiele dźwięków brzmi jednocześnie) od muzyki o uproszczonej fakturze, bazującej na pojedynczych liniach dźwiękowych.
- Napięcie harmoniczne: Obecność interwału wynoszącego 6 półtonów. Obejmuje to popularne w bluesie i jazzie akordy dominantowe septymowe. Macierz melodii poddano operacji koniunkcji z jej przesuniętą wersją (o przesunięciu równym 6) algorytm analizuje każdy ułamek sekundy (klatkę), w którym pryma i klawisz odległy o tryton są jednocześnie wciśnięte. Wynikiem przypisywanym każdemu utworowi jest stosunek czasu przebywania utworu w "stanie napięcia" do jego całkowitego czasu trwania.
- Dominacja basu: Analiza natężenia zdarzeń MIDI wyłącznie w dolnych rejestrach (poniżej wartości klawisza 45).

4. Metodyka badawcza

Zgodnie z przyjętym potokiem przetwarzania danych, surowe pliki MIDI zostały przekształcone do postaci dwukanałowych macierzy przestrzennych o wymiarach (czas $\times$ 128 wysokości tonów MIDI). Pierwszy kanał agreguje w sobie wyłącznie zsumowane ścieżki melodyczne, natomiast drugi kanał izoluje zdarzenia perkusyjne.

W procesie klasyfikacji gatunków muzycznych oraz analizy interpretowalności dla datasetu **topMAGD** zastosowano dwie architektury typu *Residual Network*:

ResNet18 oraz **ResNet34**.

Dane wejściowe (macierze MIDI) są przetwarzane w stałych blokach czasowych o długości **seq_length = 1024**. Parametr ten determinuje „okno widzenia” modelu.

Zbyt krótka sekwencja uniemożliwia sieci uchwycenie długofalowych struktur harmoniczych (np. pełnej progresji akordów). Z kolei zbyt długa sekwencja zwiększa zapotrzebowanie na pamięć VRAM i może powodować rozmycie lokalnych cech rytmicznych.

Parametr ***batch_size*** = 32 oznacza, że w każdym kroku optymalizacyjnym sieć przyjmuje tensor o wymiarach (32, 2, 128, 1024). Paczka o rozmiarze 32 zapewnia zróżnicowany podzbiór danych, gwarantujący stabilną aktualizację wag, zachowując jednocześnie naturalny "szum", który zapobiega utknięciu sieci w minimach lokalnych. Co więcej, w przypadku architektury ResNet, rozmiar paczki równy 32 pozwala na poprawne i stabilne działanie warstw normalizacji wsadowej (*Batch Normalization*). Ma to szczególne znaczenie przy wyliczaniu uśrednionych statystyk dla macierzy nutowych, które w swojej naturze są reprezentacjami wysoce rzadkimi.

Metoda TCAV opiera się na porównaniu aktywacji modelu dla badanego konceptu z tzw. „szumem”. W tym celu wygenerowano 10 folderów referencyjnych zawierających 100 losowo wybranych utworów ze zbioru uczącego. Folder referencyjny reprezentuje „naturalne” zachowanie modelu w przestrzeni ukrytej. Jeśli model reaguje na badany koncept silniej niż na losowe zbiory danych, oznacza to, że koncept posiada realną wartość dyskryminatywną dla danej klasy muzycznej.

Wynik TCAV (TCAV Score) określa, jaka część próbek danego gatunku wykazuje pozytywną korelację z badanym konceptem.

Wartość 0.5 stanowi punkt neutralny (brak wpływu konceptu na predykcję). Wyniki zbliżone do 1.0 wskazują na silny, pozytywny wpływ konceptu, natomiast wyniki bliskie 0.0 sugerują, że koncept jest dla danej klasy czynnikiem wykluczającym (wpływ negatywny).

Aby wyeliminować przypadkowe korelacje, dla każdego testu obliczono wartość *p-value* przy użyciu testu t-Studenta, weryfikującego różnicę między średnim wynikiem TCAV a wartością neutralną (0.5).

Ze względu na problem wielokrotnych porównań, zastosowano korektę Bonferroniego. Dla każdego konceptu próg istotności statystycznej ($\alpha = 0.05$) został podzielony przez liczbę analizowanych gatunków ($n = 13$):

$$\alpha = 0.05/13$$

Wyniki zostały sklasyfikowane zgodnie z poniższą logiką:

- **Status +/-:** Wartości *p-value* $\leq \alpha$, wskazujące na istotny statystycznie wpływ konceptu na klasyfikację.

- **Status NIEISTOTNE:** Wartości $p\text{-value} > \alpha$, uznane za statystycznie nieistotne, co oznacza, że wpływ konceptu na predykcję dla danego gatunku może być dziełem przypadku.

5. Wyniki eksperymentów

ResNet18 (topMAGD) - sequence length = 1024, batch_size = 32

Metryka	Wartość
Global Accuracy	0.684
Global Test Loss	1.131

Gatunek muzyczny	Precision	Recall / Accuracy	F1-Score
Pop-Rock	0.707	0.901	0.792
Blues	0.857	0.545	0.667
Jazz	0.733	0.437	0.547
Electronic	0.562	0.522	0.541
Vocal	0.800	0.384	0.519
Country	0.750	0.363	0.489

RnB	0.571	0.347	0.432
New Age	0.900	0.196	0.321
Rap	0.632	0.171	0.270
International	0.472	0.157	0.236
Latin	0.407	0.153	0.222
Reggae	0.286	0.154	0.200
Folk	0.222	0.167	0.190

ResNet34 (topMAGD)

Metryka	Wartość
Global Accuracy	0.665
Global Test Loss	1.143

Gatunek muzyczny	Precision	Recall / Accuracy	F1-Score
-------------------------	------------------	--------------------------	-----------------

Pop-Rock	0.680	0.922	0.783
Electronic	0.577	0.411	0.480
Jazz	0.827	0.336	0.478
Country	0.600	0.282	0.384
RnB	0.658	0.233	0.344
Vocal	0.591	0.191	0.289
Rap	0.571	0.190	0.286
Latin	0.386	0.191	0.256
Reggae	0.400	0.154	0.222
Blues	0.250	0.167	0.200
International	0.667	0.118	0.200
New Age	0.714	0.082	0.147
Folk	0.000	0.000	0.000

Koncept Four-on-the-floor (topMAGD)

Gatunek muzyczny	TCAV Score	P-Value	Wpływ
Reggae	0.878 (± 0.05)	0.00000	+
Electronic	0.784 (± 0.08)	0.00000	+
Rap	0.772 (± 0.14)	0.00031	+
Blues	0.591 (± 0.20)	0.20978	
Country	0.512 (± 0.33)	0.91261	
Folk	0.509 (± 0.23)	0.90625	
New Age	0.500 (± 0.28)	1.00000	
Latin	0.469 (± 0.17)	0.59720	
Pop_Rock	0.425 (± 0.21)	0.32119	
International	0.284 (± 0.16)	0.00336	-
Vocal	0.281 (± 0.30)	0.05326	

RnB	0.194 (± 0.29)	0.01121	
Jazz	0.103 (± 0.14)	0.00001	-

Koncept High Polyphony (topMAGD)

Gatunek muzyczny	TCAV Score	P-Value	Wpływ
Country	0.959 (± 0.07)	0.00000	+
Latin	0.659 (± 0.19)	0.03319	
Jazz	0.656 (± 0.27)	0.11261	
New Age	0.631 (± 0.28)	0.18630	
Folk	0.597 (± 0.13)	0.04560	
Blues	0.553 (± 0.23)	0.49816	
International	0.519 (± 0.14)	0.70254	
Vocal	0.509 (± 0.18)	0.88246	
Reggae	0.425 (± 0.22)	0.34166	

Pop_Rock	0.366 (± 0.20)	0.07717	
RnB	0.297 (± 0.27)	0.04869	
Rap	0.178 (± 0.15)	0.00012	-
Electronic	0.156 (± 0.14)	0.00004	-

Koncept Perfect Fifth (topMAGD)

Gatunek muzyczny	TCAV Score	P-Value	Wpływ
Pop_Rock	0.838 (± 0.12)	0.00002	+
Folk	0.825 (± 0.10)	0.00000	+
Vocal	0.816 (± 0.17)	0.00042	+
New Age	0.778 (± 0.11)	0.00004	+
Blues	0.725 (± 0.22)	0.01234	
Jazz	0.594 (± 0.34)	0.43584	
International	0.528 (± 0.12)	0.50179	

Country	0.463 (± 0.26)	0.67127	
RnB	0.362 (± 0.30)	0.20301	
Electronic	0.225 (± 0.14)	0.00023	-
Latin	0.194 (± 0.11)	0.00002	-
Reggae	0.166 (± 0.18)	0.00033	-
Rap	0.037 (± 0.04)	0.00000	-

Koncept Napięcie harmoniczne (topMAGD)

Gatunek muzyczny	TCAV Score	P-Value	Wpływ
Country	0.912 (± 0.13)	0.00001	+
Latin	0.812 (± 0.11)	0.00001	+
RnB	0.622 (± 0.26)	0.19575	
International	0.534 (± 0.18)	0.57450	
Blues	0.519 (± 0.22)	0.80094	

Reggae	0.519 (± 0.12)	0.65978	
Vocal	0.506 (± 0.24)	0.94013	
Pop_Rock	0.478 (± 0.24)	0.79108	
Folk	0.438 (± 0.19)	0.33829	
Jazz	0.388 (± 0.19)	0.10222	
Rap	0.325 (± 0.15)	0.00772	
Electronic	0.272 (± 0.19)	0.00516	
New Age	0.194 (± 0.15)	0.00018	-

Koncept Dominacja basu (topMAGD)

Gatunek muzyczny	TCAV Score	P-Value	Wpływ
Rap	0.953 (± 0.05)	0.00000	+
Reggae	0.906 (± 0.06)	0.00000	+
Electronic	0.791 (± 0.12)	0.00003	+

Country	0.487 (± 0.29)	0.90014	
Latin	0.416 (± 0.22)	0.27243	
Folk	0.409 (± 0.18)	0.17152	
Blues	0.362 (± 0.16)	0.03130	
RnB	0.362 (± 0.29)	0.18891	
Vocal	0.334 (± 0.21)	0.04155	
Pop_Rock	0.287 (± 0.21)	0.01306	
International	0.253 (± 0.13)	0.00025	-
New Age	0.209 (± 0.18)	0.00094	-
Jazz	0.034 (± 0.07)	0.00000	-

ResNet18 (MAGD)

Metryka	Wartość
Global Accuracy	0.612

Global Test Loss	1.352
-------------------------	-------

Gatunek muzyczny	Precision	Recall / Accuracy	F1-Score
Pop_Rock	0.646	0.882	0.746
Comedy_Spoken	0.750	0.600	0.667
Holiday	0.500	0.500	0.500
Electronic	0.506	0.445	0.474
Country	0.536	0.329	0.408
Jazz	0.528	0.269	0.357
RnB	0.529	0.259	0.348
Children	0.583	0.241	0.341
Vocal	0.424	0.212	0.283
Easy_Listening	0.352	0.200	0.255

Rap	0.407	0.175	0.244
New Age	0.538	0.152	0.237
Religious	0.471	0.145	0.222
Reggae	1.000	0.118	0.211
Stage	1.000	0.111	0.200
Latin	0.400	0.126	0.192
International	0.500	0.108	0.177
Classical	0.750	0.088	0.158
Avant_Garde	0.000	0.000	0.000
Blues	0.000	0.000	0.000
Folk	0.000	0.000	0.000

ResNet18 (MASD)

Metryka	Wartość
Global Accuracy	0.428
Global Test Loss	2.109

Gatunek muzyczny	Precision	Recall / Accuracy	F1-Score
Jazz_Classic	0.750	0.623	0.680
Big_Band	0.680	0.425	0.523
Pop_Contemporary	0.416	0.605	0.493
Rock_Hard	0.463	0.508	0.485
Dance	0.433	0.507	0.467
Experimental	0.507	0.432	0.466
RnB_Soul	0.793	0.324	0.460

Country_Traditional	0.432	0.484	0.457
Rock_Contemporary	0.439	0.469	0.454
Metal_Alternative	0.508	0.388	0.440
Blues_Contemporary	0.667	0.308	0.421
Metal_Death	0.400	0.421	0.410
Pop_Indie	0.476	0.325	0.386
Rock_Neo_Psychedelia	0.438	0.311	0.364
Grunge_Emo	0.538	0.269	0.359
Punk	0.273	0.429	0.333
Hip_Hop_Rap	0.293	0.324	0.308
Rock_College	0.325	0.290	0.307
Folk_International	0.313	0.290	0.301
Rock_Alternative	0.333	0.230	0.272

Metal_Heavy	0.500	0.154	0.235
Electronica	0.409	0.158	0.228
Pop_Latin	0.218	0.205	0.211
Gospel	0.273	0.125	0.171
Reggae	0.250	0.100	0.143

6. Wnioski końcowe

Przeprowadzona analiza metodą TCAV dostarczyła istotnych dowodów na to, w jaki sposób sztuczna sieć splotowa analizująca dwukanałowe reprezentacje symboliczne MIDI wyciąga i generalizuje cechy muzyczne. Uzyskane wyniki pozwalają na weryfikację sformułowanych hipotez badawczych:

Zgodnie z założeniami sformułowanymi w Hipotezie 1 i 2, klasyfikator z powodzeniem wykształcił wewnętrzne reprezentacje zbieżne z ludzką intuicją muzyczną. Koncept „Dominacja basu” okazał się statystycznie istotnym i silnie pozytywnym czynnikiem decyzyjnym dla gatunków Rap (TCAV Score = 0.953) oraz Electronic (TCAV Score = 0.791). Jednocześnie, dokładnie tak jak przewidywano, dla gatunków opartych na wyższych częstotliwościach (np. Folk, Vocal), model uznał ten koncept za statystycznie nieistotny (szum informacyjny). Zdolność modelu do rozpoznawania wzorców rytmicznych potwierdza również koncept „Four-on-the-floor” (stopa 4/4), który był silnie pozytywnym wektorem aktywacji dla muzyki tanecznej (Electronic, Reggae, Rap).

Eksperymenty dowodzą, że w przypadku analizy danych symbolicznych, ograniczenie złożoności architektury sieci gwarantuje wyższą stabilność wyników. ResNet18 osiągnął wyższą globalną skuteczność (Accuracy na poziomie 68.4%) niż głębszy wariant ResNet34 (Accuracy 66.5%). Szczegółowa analiza wskaźników dla poszczególnych klas ujawniła, że ResNet34 uległ drastycznemu zjawisku przeuczenia i załamania predykcji dla najmniej licznej klasy zbioru (Folk), gdzie wszystkie metryki spadły do wartości 0.000. Hipoteza 3 została udowodniona – zbyt głębokie sieci konwolucyjne przetwarzające proste, binarne lub rzadkie macierze

MIDI wykazują tendencję do zapamiętywania szumu i tracą zdolność do prawidłowej generalizacji mniejszych klas.

Analiza TCAV przyniosła niezwykle interesujące wnioski obalające część czwartej hipotezy. Założono w niej, że dysonansowy interwał trytonu (napięcie harmoniczne) będzie rozpoznawany jako pozytywny sygnał dla gatunków o wysoce złożonej harmonii, takich jak Jazz. Wyniki jednoznacznie wykazują jednak, że dla Jazzu koncept ten okazał się statystycznie nieistotny ($p\text{-value} = 0.10222$), co oznacza, że sieć traktuje go jedynie jako szum. Pomimo obiektywnej obecności dysonansów w utworach jazzowych, model uznał je za zbyt trudne do wyizolowania lub nieistotne, opierając predykcję Jazzu na zupełnie innych korelacjach. Zgodnie z drugą częścią Hipotezy 4 potwierdzono natomiast, że koncept trytonu jest czynnikiem mocno wykluczającym (wpływ negatywny, $TCAV = 0.194$) dla muzyki o charakterze konsonansowym, takiej jak New Age.

Na szczególną uwagę zasługuje również zachowanie konceptu Perfect Fifth. Model trafnie zidentyfikował go jako najsilniejszy pozytywny predyktor dla muzyki Pop-Rock ($TCAV\ Score = 0.838$), a jednocześnie jako czynnik silnie wykluczający (negatywny) dla gatunków takich jak Rap (0.037) czy Electronic (0.225). Wyniki te wskazują, że sieć nauczyła się wykorzystywać występowanie tego konkretnego interwału w strukturze MIDI jako istotną cechę dyskryminującą, pozwalającą na skuteczne rozróżnienie tych gatunków muzycznych.”

Ewaluacja modelu na 21-klasowym zbiorze MAGD dostarczyła informacji na temat skalowalności architektury względem 13-klasowego topMAGD. Rozszerzenie spowodowało przewidywalny spadek globalnej dokładności modelu ResNet18 z 68.4% do 61.2%. Utrzymanie skuteczności powyżej 60% przy tak dużym rozdrobnieniu klas dowodzi jednak, że dwukanałowa ekstrakcja cech (melodia i perkusja) pozwala na silną generalizację. Z drugiej strony, testy na pełnym zbiorze MAGD uwypukliły podatność klasyfikatorów splotowych na skrajne niebalansowanie danych. Dla gatunków niszowych i awangardowych (np. Avant_Garde, Folk, Blues) model uległ tzw. mode collapse, sprowadzając wszystkie metryki do zera na rzecz częstszych, „bezpiecznych” klas. Ponadto trudniejszy zbiór sprawił, że model stał się skrajnie zachowawczy w swoich predykcjach – dla specyficznych gatunków, takich jak Reggae czy Stage, model zmaksymalizował precyzję (1.000) przy drastycznym spadku czułości (~ 0.11). Oznacza to, że sieć unika jakiegokolwiek ryzyka i predykuje te klasy wyłącznie dla utworów o „podręcznikowej” strukturze.

Dalsza ewaluacja modelu na najbardziej szczegółowym, 25-klasowym podziale gatunkowym (MASD) uwypukla ostateczne granice klasyfikatora operującego wyłącznie na danych symbolicznych. Narzucenie tak dużej szczegółowości skutkuje spadkiem globalnej dokładności do poziomu 42.8%. Wynika to bezpośrednio ze zjawiska silnego nakładania się na siebie cech (ang. class overlap) wewnątrz bardzo

zbliżonych podgatunków – płytka sieć ResNet18 traci zdolność do precyzyjnego rozróżnienia niuansów pomiędzy pokrewnymi stylami, takimi jak Rock Alternative, Rock College czy Rock Contemporary. Z drugiej strony, nawet przy tak wysokim rozdrobnieniu, model wykazuje wysoką stabilność w identyfikowaniu gatunków o fundamentalnie odmiennej budowie harmoniczej. Klasy takie jak Jazz Classic czy Big Band nadal osiągają najwyższe wyniki w zestawieniu (F1-Score na poziomie 0.520 – 0.680), a predykcje dla RnB Soul oraz Blues Contemporary cechują się znakomitą precyzją (rzędu 0.667 – 0.793). Stanowi to dowód na to, że o ile klasyfikator splotowy MIDI gubi się w subtelnych podziałach stylistycznych wewnątrz jednego nurtu, o tyle potrafi bardzo dobrze izolować główne struktury muzyczne.